



دانشگاه صنعتی شریف

دانشکده مهندسی صنایع

مبانی داده کاوی (Data Mining)

پروپوزال انتخاب دیتاست

استاد راهنما:

دکتر مریم بستان آرا

گردآورندگان:

۱. صبا یوسفزاده - ۴۰۱۱۰۴۵۷۶

۲. سجاد سعیدی - ۴۰۲۱۰۴۱۷۷

نیم سال تحصیلی: بهار ۱۴۰۵

فهرست مطالب

۱	پروپوزال انتخاب دیتاست	۲
۱.۱	اولویت اول: دیتاست نکول مشتریان کارت اعتباری (Default of Credit Card Clients)	۲
۲.۱	اولویت دوم: دیتاست کمپین بازاریابی بانکی (Bank Marketing)	۲

۱ پروپوزال انتخاب دیتاست

۱.۱ اولویت اول: دیتاست نکول مشتریان کارت اعتباری (Default of Credit Card Clients)

لینک دیتاست: <https://archive.ics.uci.edu/dataset/350/default+of+credit+card+clients>

مشخصات کلی دیتاست: این دیتاست ۳۰,۰۰۰ سطر (مشتری) و ۲۳ ستون دارد. داده‌های آن از نوع ترکیبی هستند؛ یعنی هم اطلاعات فردی و دسته‌ای (مثل سن، جنسیت و میزان تحصیلات) در آن وجود دارد و هم داده‌های کاملاً عددی (مثل مبلغ صورت‌حساب‌ها و تاخیرهای پرداخت در ۶ ماه گذشته).

سؤال تحقیق: ما می‌خواهیم بررسی کنیم که آیا با تحلیل سابقه پرداخت‌ها و رفتار مالی مشتریان در شش ماه گذشته، می‌توانیم پیش‌بینی کنیم که یک نفر قسط وام خود را پس می‌دهد یا نه؟ هدف این است که یک مدل اعتبارسنجی بسازیم تا بانک بتواند مشتریان پرخطر را شناسایی کرده و جلوی ضررهای مالی را بگیرد.

دلیل انتخاب دیتاست: راستش را بخواهید، به عنوان دانشجوی مهندسی صنایع، مباحث ارزیابی ریسک و سیستم‌های مالی همیشه برایمان جذاب بوده است. دلیل اصلی که این دیتاست را به عنوان اولویت اول انتخاب کردیم این است که داده‌های مربوط به ۶ ماه گذشته در ستون‌های جداگانه قرار دارند. این یعنی ما نباید فقط داده‌ها را به شکل خام به خورد مدل بدهیم؛ بلکه می‌توانیم خودمان دست به کار شویم و ویژگی‌های جدیدی بسازیم (مثلاً نسبت بدهی به پرداختی را حساب کنیم). از طرف دیگر، در این دیتاست فقط ۲۲ درصد افراد وامشان را نداده‌اند. این یعنی با مشکل کلاس‌های نامتوازن روبه‌رو هستیم و متوجهیم که نمی‌توانیم فقط به دقت ساده (Accuracy) تکیه کنیم. استفاده از روش‌هایی مثل SMOTE برای بالانس کردن داده‌ها، چالش فنی خیلی خوبی برای یادگیری ما در این پروژه است.

۲.۱ اولویت دوم: دیتاست کمپین بازاریابی بانکی (Bank Marketing)

لینک دیتاست: <https://archive.ics.uci.edu/dataset/222/bank+marketing>

مشخصات کلی دیتاست: این فایل شامل ۴۱,۱۸۸ سطر و ۲۰ ستون است. داده‌ها از نوع ترکیبی هستند؛ یعنی علاوه بر ویژگی‌های عددی (مثل سن یا موجودی حساب) و دسته‌ای (مثل نوع شغل و وضعیت تاهل مشتری)، یک سری متغیرهای مربوط به شرایط اقتصاد کلان (مثل نرخ تورم و نرخ بهره) هم در آن قرار دارد.

سؤال تحقیق: بانک‌ها برای جذب سپرده، هزینه‌های زیادی صرف تماس‌های تلفنی می‌کنند که خیلی از آن‌ها بی‌نتیجه است. ما می‌خواهیم مدلی بسازیم که با بررسی شرایط مشتری، پیش‌بینی کند آیا او پیشنهاد بانک را قبول می‌کند یا

خیر؟ با این کار، بانک فقط به کسانی زنگ می‌زند که احتمال موفقیتشان بالا باشد و به این شکل در هزینه‌های مرکز تماس صرفه‌جویی می‌شود.

دلیل انتخاب دیتاست: این موضوع دقیقاً با بحث بهینه‌سازی سیستم‌ها و مدیریت ارتباط با مشتری (CRM) که در رشته خودمان می‌خوانیم هم‌خوانی دارد. از نظر فنی دو چالش خیلی جالب در این دیتاست دیدیم: اول اینکه فقط ۱۱ درصد آدم‌ها پیشنهاد بانک را قبول کرده‌اند؛ پس پیدا کردن این اقلیت برای مدل سخت است و ما باید حواسمان به معیار Recall باشد تا مشتری‌های خوب را به اشتباه از دست ندهیم. چالش دوم که خیلی دوستش داشتیم، وجود ستونی به نام «مدت زمان تماس» است. مشخص است که اگر کسی ۱۰ دقیقه با اپراتور حرف زده، احتمالاً راضی شده است! اما در دنیای واقعی، ما قبل از تماس گرفتن نمی‌دانیم مکالمه چقدر طول می‌کشد. پس برای اینکه مدلمان اصطلاحاً تقلب نکند (یا همان نشت اطلاعات Data Leakage اتفاق نیفتد)، باید این ستون را حذف کنیم و مدل را فقط با اطلاعات قبل از تماس آموزش دهیم.